Generalização de classificadores de defeitos em grãos de soja entre equipamentos: um estudo com dados abertos

Thalles Paul Leandro Mota

Relatório técnico – novembro de 2026

Resumo. *Equipamentos que classificam grãos de soja por imagem só padronizam a classificação se o modelo mantiver o desempenho em unidades onde não foi treinado. Este relatório mede essa perda com duas bases públicas (10.343 imagens), tratando três regiões como três unidades de equipamento. Separar as fotos uma a uma, e não por bandeja, inflou a acurácia balanceada em 4,4 pontos. Numa unidade nunca vista, o modelo perdeu 14,2 pontos, recuperados quando parte das amostras da unidade entrou no treino. Entre bases de origens diferentes, o desempenho caiu ao nível do acaso; 50 imagens rotuladas da base nova levaram a acurácia a 86,9. Enviar à revisão humana os 10% de grãos mais duvidosos elevou a acurácia de 91,4 para 95,2 em unidade conhecida, mas pouco ajudou em unidade nova, onde o modelo erra com confiança. Das seis previsões registradas antes dos testes, 4 se confirmaram.*

1. Introdução

No Brasil, a soja é classificada pelo padrão oficial do Ministério da Agricultura [MAPA 2007]. Numa amostra de cada carga, um classificador separa visualmente os grãos avariados (mofados, ardidos, imaturos, picados por percevejo, entre outros) e pesa cada grupo; na dúvida, o grão é cortado. Na soja do Grupo II, acima de 8% de avariados a carga fica fora de tipo. A safra 2025/26 somou 180,4 milhões de toneladas [Conab 2026], e essa separação se repete a cada carga recebida.

Equipamentos que fotografam cada grão e o classificam com um modelo de aprendizado de máquina prometem rapidez e o mesmo critério em todas as unidades. Esse benefício depende de uma condição: o modelo precisa manter o desempenho numa unidade em que não foi treinado, com outra câmera, outra iluminação, outra região e outro classificador de referência. Este estudo responde a três perguntas: (i) quanto o modelo perde numa unidade nova; (ii) por que perde; e (iii) quanto dado novo, e de que tipo, recupera o desempenho.

2. Dados

A base SOYPR [Pereira et al. 2024] contém 4.830 imagens de grãos de três regiões do Paraná, em sete classes (intacto, cercospora, esverdeado, dano mecânico, percevejo, sujo e umidade). Cada grão foi fotografado três vezes numa bandeja, e cada região foi rotulada por um especialista. Neste estudo, cada região faz o papel de uma unidade de equipamento.

A base Mendeley [Lin et al. 2023] contém 5.513 imagens de outra origem, em cinco classes, sob licença CC BY 4.0. A auditoria encontrou 371 pares de imagens repetidas (290 idênticas byte a byte e 81 recomprimidas) e um conflito de rótulo; mantive uma imagem por grupo de cópias e excluí o conflito, restando 5.141 imagens. Como as duas

bases não têm as mesmas classes, a comparação entre elas usa a tarefa comum: intacto ou defeituoso.

3. Protocolo de avaliação

Divisões. Treino e teste foram definidos antes de qualquer modelo, por bandeja física na SOYPR e por grupo de cópias na Mendeley, e congelados com código de verificação (SHA-256). Testes automatizados falham se uma bandeja ou cópia aparecer nos dois lados. Dentro de cada unidade, 20 partições aleatórias das bandejas em duas metades, cada uma usada nas duas direções.

Modelo de referência. O melhor modelo do artigo da SOYPR: as 1.000 saídas de uma rede ViT-Base pré-treinada [Dosovitskiy et al. 2021], padronizadas e classificadas por uma SVM com núcleo RBF. Os hiperparâmetros (C e γ, 110 pares) foram escolhidos só com dados de treino; o conjunto de teste nunca participou de nenhuma escolha.

Métricas. Acurácia balanceada (média do acerto por classe) como métrica principal; acerto por classe e matrizes de confusão; F1 ponderado apenas para comparação com a literatura. A incerteza vem da reamostragem de bandejas inteiras, não de grãos isolados.

Previsões. Seis previsões, cada uma com critério de acerto, foram registradas antes dos testes.

4. Resultados

4.1. Separar por foto infla o resultado

As três fotos de um grão são quase idênticas. Se uma fica no treino e outra no teste, o modelo reconhece o grão em vez de classificar o defeito. A Figura 1 compara as duas formas de separar, com o mesmo modelo e o mesmo ajuste.

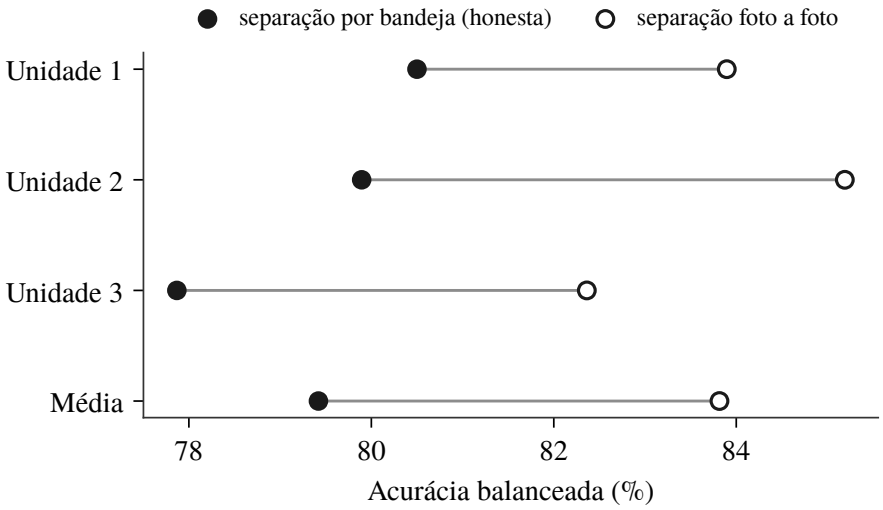


Figura 1. Acurácia balanceada com separação por bandeja e foto a foto (média de 20 repetições).

A separação foto a foto inflou a acurácia balanceada em 4,4 pontos, nas três unidades; a pior repetição foto a foto ficou acima da melhor por bandeja. Com a avaliação

honesta, o modelo do artigo chegou a 71,8 de F1 ponderado por grão, contra 85,1 publicados; mesmo escolhendo os hiperparâmetros pelo teste, o teto ficou em 74,8. O artigo não informa a versão dos pesos nem o preparo das imagens, e o número honesto foi adotado como referência.

4.2. Unidade nunca vista

A Figura 2 compara, nas mesmas bandejas de teste, o modelo treinado na própria unidade, o treinado só nas outras duas e o modelo geral que inclui metade das bandejas da unidade.

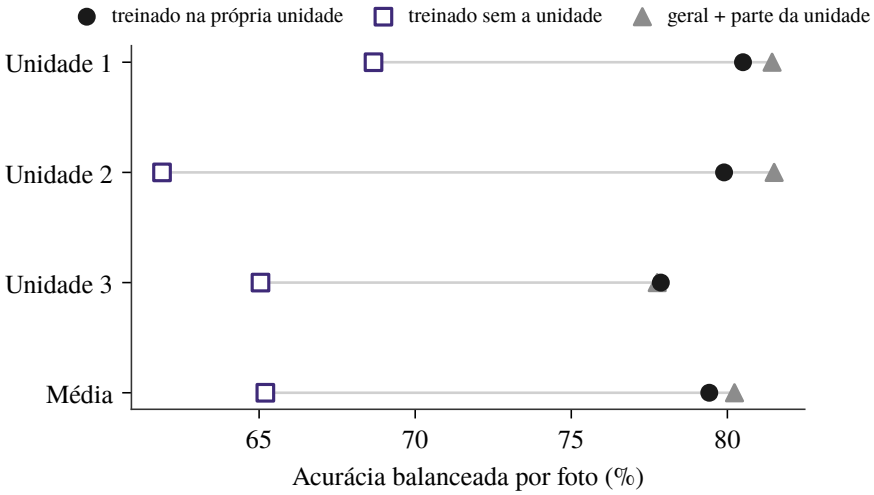


Figura 2. Acurácia balanceada por foto nas mesmas bandejas de teste de cada unidade.

A perda média numa unidade nunca vista foi de 14,2 pontos (79,4 para 65,2), na mesma direção nas 20 repetições. Com parte das bandejas da unidade no treino, o modelo geral chegou a 80,2, no nível do modelo local. O caso extremo foi a classe "sujo" na unidade 2: 100% de acerto com o modelo local e 9% sem dados dessa unidade. Os autores da base descrevem essa classe como sujeita à subjetividade dos classificadores [Pereira et al. 2024], o que indica critério de rotulagem próprio de cada região.

4.3. Outra base de imagens

Na tarefa intacto ou defeituoso, um modelo treinado numa base e aplicado na outra caiu ao nível do acaso (50,1 e 52,3 de acurácia balanceada, contra 93,6 e 94,1 dentro de cada base), classificando quase todos os grãos como defeituosos. A capacidade de ordenar os grãos também caiu (AUC de 0,82 e 0,72, contra 0,98 a 0,99 dentro de cada base), de modo que ajustar apenas o limiar de decisão não basta. A Figura 3 mostra quanto dado rotulado da base nova recupera o desempenho.

Treinar só com as imagens novas foi a melhor estratégia: 86,9 com 50 imagens e 90,3 com 200, perto dos 94,7 da base inteira. Juntar as imagens novas com a base antiga foi pior, e ajustar só o limiar parou em 74,3. Na Mendeley, mais difícil, os valores foram 70,1 e 81,1.

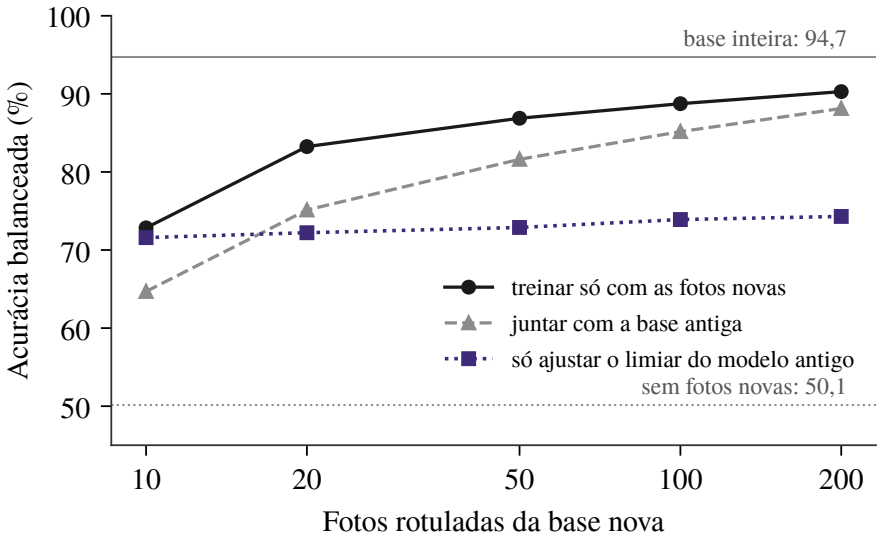


Figura 3. SOYPR como base nova: acurácia balanceada medida sempre em bandejas fora do sorteio (20 sorteios por ponto).

4.4. Troca do extrator de características

O artigo da SOYPR comparou cinco redes, todas com SVM, e o SVM superou uma rede neural simples. Por isso o classificador foi mantido e só a rede que descreve a imagem foi trocada (Tabela 1).

Tabela 1. Acurácia balanceada por foto com três redes pré-treinadas, sempre com SVM.

Rede	Própria unidade	Unidade nunca vista	Perda
ViT-Base [Dosovitskiy et al. 2021]	79,4	65,2	−14,2
DINOv2 [Oquab et al. 2024]	80,0	69,4	−10,6
CLIP [Radford et al. 2021]	73,3	60,0	−13,3

O DINOv2 perdeu menos na unidade nova (+4,2 pontos sobre o ViT-Base, à frente nas 20 repetições), sem eliminar a perda. Nenhuma das três redes resolveu a troca de base.

4.5. Dúvida do modelo e revisão humana

Um comitê com as duas melhores redes atribui a cada grão uma classe e um grau de dúvida. A Figura 4 mostra o efeito de enviar à revisão humana os grãos mais duvidosos.

Em unidade conhecida, revisar 10% dos grãos elevou a acurácia de 91,4 para 95,2 e capturou 56% dos erros. Em unidade nova, a mesma revisão capturou só 27% dos erros: o modelo erra com confiança, e a dúvida aponta os erros pior fora (AUC 0,77) do que em casa (0,88). A análise da dificuldade de cada grão [Smith et al. 2014] separou dois tipos de erro: grãos ambíguos já na própria unidade e grãos fáceis em casa que o modelo erra fora, típicos da classe “sujo” na unidade 2.

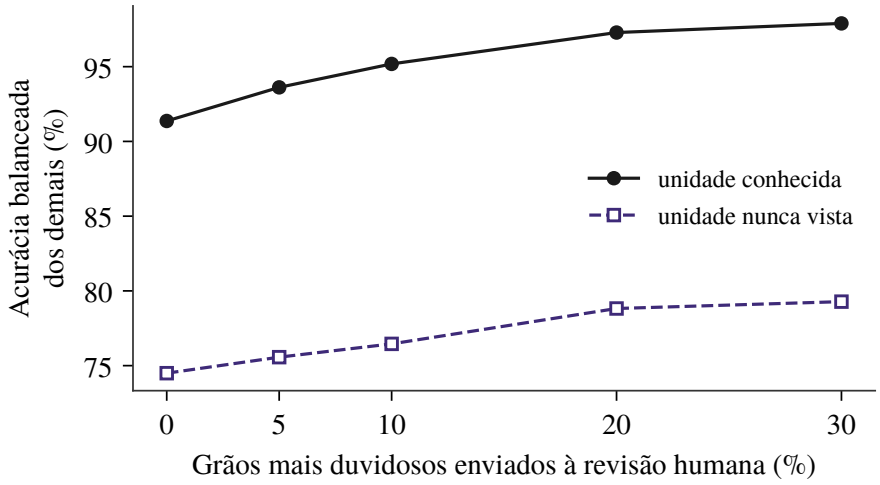


Figura 4. Acurácia balanceada por grão dos grãos que permanecem com o modelo.

5. Previsões registradas antes dos testes

Tabela 2. Previsões, resultado e veredito.

	Previsão	Resultado	Veredito
P1	Dividir por foto, em vez de por bandeja, infla o resultado.	+4,4 pontos, nas 3 unidades	confirmada
P2	Sem a unidade 2 no treino, o “sujo” é o defeito mais afetado.	“sujo”: de 100% para 9% de acerto	confirmada
P3	Dano mecânico e dano por umidade terão o pior recall em todas as divisões.	os dois piores em 3 de 9 casos	não confirmada
P4	A queda ao trocar de base será muito maior do que ao trocar de unidade.	43,5 contra 0,8 pontos	confirmada
P5	Na Mendeley, a divisão sem tratar cópias infla o recall de intacto.	92,9% contra 90,8% (4 de 5 partes; efeito pequeno)	confirmada
P6	A insegurança será maior na unidade não vista e vai se concentrar em mecânico, umidade e no “sujo” da unidade 2.	maior fora: sim; “sujo” da unidade 2: sim; mecânico entre os mais inseguros: não	não confirmada

As duas previsões não confirmadas erraram no mesmo ponto: o dano mecânico não foi a classe mais difícil; esverdeado, umidade e percevejo foram.

6. Limites de uso e recomendações

Tabela 3. Recomendações por situação, com os valores medidos neste estudo.

Situação	Recomendação	Acurácia bal.
Equipamento conhecido	comitê de duas redes; revisar os 10% mais duvidosos	91,4 → 95,2
Equipamento novo, sem dados dele	validar antes de usar	76,8
Equipamento novo, com parte das amostras dele	modelo geral com os dados da unidade	87,8
Outra base de imagens, sem imagens dela	não usar	acaso
Outra base, 50 ou 200 imagens rotuladas	treinar só com as imagens novas	86,9 ou 90,3

Os valores das três primeiras linhas são por grão; os das duas últimas, por imagem, na tarefa intacto ou defeituoso. Em ordem de prioridade, o estudo sugere: (i) avaliar sempre por amostra e por unidade, antes de alterar o modelo; (ii) coletar e rotular amostras de cada unidade nova antes de operá-la; (iii) usar a dúvida do modelo para orientar a revisão humana em unidades conhecidas; (iv) alinhar o critério de rotulagem entre unidades; e (v) avaliar extratores de características mais recentes, sem esperar que substituam os dados da unidade.

7. Limitações

As unidades deste estudo são regiões fotografadas, e não equipamentos distintos; os efeitos do equipamento, da região e do classificador de referência não se separam. As redes foram usadas sem retreino. A comparação entre bases usa apenas a tarefa intacto ou defeituoso, porque as bases não têm as mesmas classes. As imagens da SOYPR não são reproduzidas porque a base não declara licença de uso.

Referências

Conab (2026). Acompanhamento da safra brasileira de grãos, v. 13, safra 2025/26, 12º levantamento.

Dosovitskiy, A. et al. (2021). An image is worth 16x16 words: transformers for image recognition at scale. In *ICLR*.

Lin, W. et al. (2023). Soybean image dataset for classification. *Data in Brief*, 48:109300.

MAPA (2007). Instrução Normativa n. 11, de 15 de maio de 2007: Regulamento Técnico da Soja.

Oquab, M. et al. (2024). DINOv2: learning robust visual features without supervision. *Transactions on Machine Learning Research*.

Pereira, G. M. L., Foleis, J. H., Brito Jr., A. S. e Bertolini, D. (2024). A database for soybean seed classification. In *37th SIBGRAPI*. IEEE.

Radford, A. et al. (2021). Learning transferable visual models from natural language supervision. In *ICML*.

Smith, M. R., Martinez, T. e Giraud-Carrier, C. (2014). An instance level analysis of data complexity. *Machine Learning*, 95:225–256.