Aprendizado de máquina multirregional em saúde mental de adolescentes: síntese de três estudos com a PeNSE 2019

Thalles Paul Leandro Mota

Relatório técnico – novembro de 2026

Resumo. *Este relatório sintetiza três estudos publicados em 2026 que aplicam aprendizado de máquina aos dados da Pesquisa Nacional de Saúde do Escolar (PeNSE 2019) para identificar adolescentes em risco, sempre avaliando os modelos em estados que não participaram do treino. O primeiro classificou o risco de uso frequente de substâncias no Centro-Oeste, com validação em Mato Grosso (AUROC 0,89; recall 0,80). O segundo classificou sofrimento psicológico em escala nacional, com treino em uma unidade da federação por macrorregião e avaliação nas 22 restantes (AUROC 0,87; F2 0,71), e mostrou que a sensibilidade se mantém sem a variável de tristeza. O terceiro investigou de onde vem a dificuldade desses problemas e concluiu que ela depende mais da definição do alvo do que das variáveis disponíveis. Juntos, os estudos formam um protocolo de validação geográfica, interpretação estável e diagnóstico de limites aplicável a triagem em saúde pública.*

1. Contexto

A adolescência concentra vulnerabilidades que vão do uso de substâncias ao comportamento suicida; o suicídio é a segunda principal causa de morte entre jovens de 15 a 24 anos no mundo [Gerstner et al. 2018]. No Brasil, a PeNSE, conduzida pelo IBGE, coleta dados de saúde de escolares em todo o país [IBGE 2021], o que permite construir classificadores para triagem. Um país de dimensões continentais impõe, porém, uma exigência que estudos com validação aleatória não testam: um modelo construído com dados de alguns estados precisa funcionar nos demais.

Os três estudos aqui reunidos, realizados em coautoria com C. A. Martins, L. C. O. Gonçalves, A. C. S. de Oliveira e L. A. V. Garcia, respondem a perguntas complementares: (i) é possível classificar o risco com bom desempenho em estados não vistos? (ii) os critérios aprendidos pelos modelos são estáveis e interpretáveis? (iii) de onde vem o limite de desempenho?

2. Desenho comum

Os estudos compartilham a fonte de dados (PeNSE 2019), a ênfase em sensibilidade, já que em triagem deixar de identificar um adolescente em risco custa mais que um alarme falso, e a validação geográfica: o treino usa alguns estados, e a avaliação usa estados que o modelo nunca viu. A Tabela 1 resume cada estudo.

Tabela 1. Os três estudos.

	Estudo 1 [Mota e Martins 2026]	Estudo 2 [Mota et al. 2026a]	Estudo 3 [Mota et al. 2026b]
Desfecho	uso frequente de substâncias (3 ou mais dias em 30)	sofrimento psicológico (sentir que a vida não vale a pena na maior parte do tempo ou sempre)	uso frequente de substâncias, em três variantes
Escopo	Centro-Oeste	Brasil	Brasil
Validação geográfica	treino em MS, GO e DF; teste em MT	treino em uma UF por macrorregião; teste nas 22 UFs restantes; 10 sorteios	mesmo desenho do estudo 2; 10 sorteios
Modelos	XGBoost e floresta aleatória; Optuna (300 iterações)	XGBoost, CatBoost e LightGBM; Optuna (12.000 iterações)	comitê de 4 modelos e uma rede neural de controle
Pergunta central	o risco é detectável fora dos estados de treino?	os critérios são estáveis e auditáveis?	a dificuldade vem das variáveis ou do alvo?

3. Estudo 1: uso frequente de substâncias no Centro-Oeste

Com treino em Mato Grosso do Sul, Goiás e Distrito Federal (10.348 registros, prevalência de 5,3%) e validação exclusiva em Mato Grosso (3.277 registros, prevalência de 5,6%), o XGBoost otimizado para recall atingiu, nas dez configurações reportadas, AUROC de 0,89, recall entre 0,80 e 0,81 e precisão de cerca de 0,23 [Mota e Martins 2026]. O XGBoost manteve o recall mais estável que a floresta aleatória. A análise com SHAP indicou como preditor de maior peso ter amigos fumantes, seguido do uso recente de álcool e da vida sexual ativa, e identificou fatores de proteção, como supervisão familiar e apoio dos pais.

4. Estudo 2: sofrimento psicológico em escala nacional

Com 105.116 registros válidos e prevalência de 19,8% (de 17,3% no Sul a 22,0% no Norte), o estudo sorteou uma unidade da federação por macrorregião para o treino e avaliou os modelos nas 22 restantes, repetindo o sorteio dez vezes [Mota et al. 2026a]. Para separar critérios reais de artefatos da busca, foram definidos cinco índices de estabilidade sobre os valores de SHAP dos modelos de melhor desempenho, e esses critérios foram comparados com a associação estatística de cada variável com o desfecho (V de Cramér). A correlação foi positiva em todos os sorteios, e um núcleo de variáveis se repetiu em todos eles, incluindo autopercepção corporal, apoio dos pais, bullying e escola pública.

Em estados não vistos, o XGBoost atingiu AUROC de 0,87, F2 de 0,71 e recall de 0,84. Sem a variável de tristeza, a mais associada ao desfecho, AUROC e F2 caíram para 0,80 e 0,64, mas o recall praticamente não mudou (0,83; diferença não significativa no teste de Wilcoxon pareado): a capacidade de triagem se sustenta com variáveis sociodemográficas e de contexto. Um índice aditivo de risco construído diretamente dos pesos de SHAP (RII), sem modelagem de interações, ficou a 0,016–0,021 de F2 do classificador, o que o torna um instrumento auditável. O desempenho variou entre macrorregiões de forma estável, com o Centro-Oeste no topo e o Nordeste na base (Figura 1).

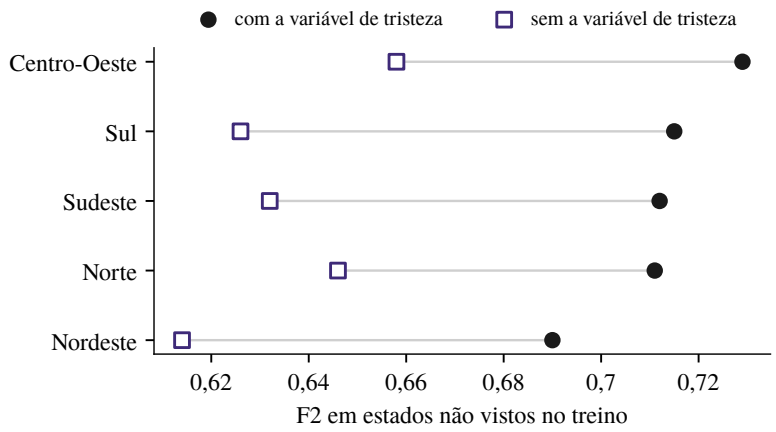


Figura 1. F2 mediano do sistema combinado (RII e classificador) por macrorregião, em estados fora do treino, com e sem a variável de tristeza (dez sorteios; dados da Tabela 5 de [Mota et al. 2026a]).

5. Estudo 3: de onde vem a dificuldade

Com 165.838 adolescentes e prevalência de cerca de 4%, o terceiro estudo mediu a dificuldade de cada instância de duas formas independentes: pela propensão ao erro de um comitê de quatro modelos (*instance hardness*) e pela sobreposição local entre classes (kDN), que não usa modelo [Mota et al. 2026b, Smith et al. 2014]. A dificuldade mostrou-se, em grande parte, propriedade dos dados: a concordância entre os quatro modelos superou 0,94 (Spearman). A sobreposição local explicou só parte dos erros (AUC de cerca de 0,73, contra 0,95 da medida empírica), o que aponta para ruído de rótulo ou interações não locais.

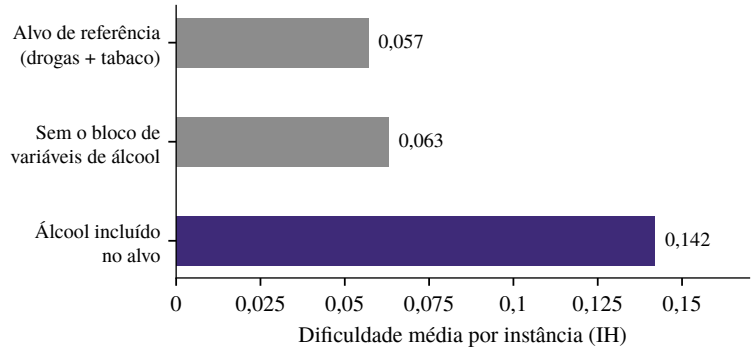


Figura 2. Dificuldade média por instância em três variantes do mesmo problema (dez sorteios; dados de [Mota et al. 2026b]).

O resultado central está na Figura 2: remover todo o bloco de variáveis de álcool, mantendo as mesmas instâncias e o mesmo alvo, quase não alterou a dificuldade (0,057 para 0,063; diferença mediana pareada de $-0{,}0004$), enquanto ampliar o alvo para incluir o álcool a elevou cerca de 2,5 vezes (0,057 para 0,142), com a taxa de erro do comitê subindo de 9% para 18%. Nesse domínio, passado um conjunto razoável de variáveis, o teto de desempenho depende mais do que se prevê do que das variáveis usadas para prever.

6. O que os três estudos ensinam juntos

1. **Validar fora dos dados de treino muda a conclusão.** A avaliação em estados não vistos revela heterogeneidade regional que uma divisão aleatória esconderia; limiares calibrados por região absorvem parte dela.
2. **Em triagem, a métrica decide o modelo.** Priorizar o recall (ou o F2) aceita mais alarmes falsos em troca de não perder casos de risco; a escolha precisa ser explícita.
3. **Interpretação só vale se for estável.** Critérios que se repetem entre sorteios e convergem com a associação estatística independente podem virar instrumentos auditáveis, como o RII.
4. **Antes de buscar mais variáveis, examine o alvo.** A definição do desfecho pode ser a principal fonte de dificuldade.

A mesma lógica (treinar numa parte das fontes de dados, avaliar nas demais e diagnosticar a origem dos erros) aplica-se a qualquer modelo que precise funcionar fora do contexto em que foi construído.

7. Limitações

Os dados são de 2019, anteriores à pandemia. Os desfechos são autorrelatados e funcionam como indicadores de sofrimento ou risco, não como diagnóstico clínico; os sistemas foram pensados para triagem e monitoramento. No estudo 2, os pesos amostrais da pesquisa não foram usados, pois o objetivo é a predição individual e não a inferência populacional, e os blocos da análise regional não são totalmente independentes. No mesmo estudo, a verificação de equidade por cor ou raça indicou recall entre 0,81 e 0,87 nos cinco grupos, e uma análise mais ampla fica para trabalhos futuros [Mota et al. 2026a].

Referências

Gerstner, R. M. F., Soriano, I., Sanhueza, A., Caffe, S. e Kestel, D. (2018). Epidemiología del suicidio en adolescentes y jóvenes en Ecuador. *Revista Panamericana de Salud Pública*, 42:1–7.

IBGE (2021). Pesquisa Nacional de Saúde do Escolar: 2019. Rio de Janeiro: IBGE.

Mota, T. P. L. e Martins, C. A. (2026). Aprendizado de máquina na classificação do risco de uso frequente de substâncias em adolescentes na região Centro-Oeste. In *Anais do Congresso de Inteligência Artificial de Mato Grosso*. doi:10.29327/9786527222910.1448987.

Mota, T. P. L., Gonçalves, L. C. O., Oliveira, A. C. S. e Martins, C. A. (2026). Classifying psychological distress in Brazilian adolescents: a multi-regional machine learning approach. In *Intelligent Systems (BRACIS 2026)*, LNAI 17109, p. 546–560. Springer. doi:10.1007/978-3-032-39904-5_37.

Mota, T., Garcia, L. A. V. e Martins, C. (2026). Where does hardness come from? An instance hardness analysis of substance-use prediction in Brazilian adolescents. In *Anais do XIV KDMiLe*, p. 265–272. SBC. doi:10.5753/kdmile.2026.31988.

Smith, M. R., Martinez, T. e Giraud-Carrier, C. (2014). An instance level analysis of data complexity. *Machine Learning*, 95:225–256.